

16 Reflection.

1. Prediction dự đoán sai.

- Tỷ lệ zero entries: thực tế lên tới 99,91% trên tổng số $5,59 \times 10^9$ phần tử
- Dự đoán vocabulary size: thực tế chỉ có 186,582 token

2. Kết quả gây bất ngờ nhất:

- Sự chênh lệch giữa OOV và Search Performance của Subword Tokenization (BPE). Tỷ lệ OOV bị giảm gần mức tối thiểu 0,31% nhưng điểm Cosine tương đồng tăng lên TF-IDF lại thấp nhất 0,18%

3. Experiment 2 cung cấp evidence mạnh nhất

- Cung cấp bằng chứng thực nghiệm rõ ràng nhất
- Số liệu: Thao tác lược bỏ stop words làm giảm gần nửa độ dài văn bản (381,9 $\rightarrow$ 202,4 token/doc) đáng độ thưa loãng cao nhất (99,8% và năng điểm tương đồng lên cao nhất (0,2510)

4. Failure case quan trọng nhất là hiện tượng lệch từ vựng.

Ví dụ: query: heart attack treatment

Kết quả cho được Cosine Similarity là 0.000

Dù 2 câu cùng lý y khoa nhưng vì không trùng từ vựng nên TF-IDF $\neq 0$

5. Chuyển dịch sang Hybrid Search

Kết hợp lexical matching (BM25/TF-IDF) để giữ thứ hạng tìm kiếm từ hiển / mã số chính xác, song song với dense vector search để nắm bắt ngữ nghĩa tổng thể

6. Phân AI đóng góp:

Cải pháp nhận matrix thưa chuẩn hóa L_2 để tính Cosine Similarity tức thời trên 30k docs.

Hỗ trợ chỉnh dạng, tự động hóa các ô cell, note book