

1. Prediction trước experiment.

1. Prediction 1: Kích thước từ vựng (IVI).

Dự đoán: K^o đổi khi tăng từ Unigram $\rightarrow$ Bigram $\rightarrow$ Trigram

Lý do: Từ vựng chỉ tính số lượng từ đơn, phân biệt trong ngữ liệu, việc ghép cặp hay ba từ không làm thay đổi tập từ vựng nên vậy.

Độ tin cậy: Cao (90%)

Kiểm chứng: Đúng. Cả 3 mô hình đều dùng chung tập IVI = 186 từ.

2. Prediction 2: Số lượng n-gram phân biệt

Dự đoán tăng vọt theo bậc n ($N_{unigram} \ll N_{bigram} \ll N_{trigram}$)

Lý do: K^o gian 15^o hợp mở rộng theo IVI, cách ghép từ trong câu sẽ đa dạng nên số lượng từ mới tăng cực nhanh theo độ dài.

Độ tin cậy: 95%

Kiểm chứng: Đúng.

Unigram: 186

Bigram: 27390 (gấp ≈ 14.7 lần)

Trigram: 690458 (gấp ≈ 34 lần)

3 Prediction 3: Ngụy cơ gặp Zero Probability

Dự đoán: Trigram dễ gặp nhất đến Bigram còn Unigram

Lý do: Không gian của Trigram quá rộng nên tập dữ liệu chỉ bao phủ một phần rất nhỏ, cái mới sẽ dễ chui vào chỗ chưa từng xuất hiện

Độ tin cậy: 95%

Kiểm chứng: Đúng

Tỉ lệ n-gram chi xuất hiện tần tăng mạnh: Unigram (47,41%)

→ Bigram (71,5%) → Trigram (86,21%)

Trên tập test cả Bigram MLE và Trigram MLE đều bị $PPL = \infty$

4 Prediction 4: Perplexity trên Training Set.

Dự đoán: Trigram MLE đạt Perplexity thấp nhất

Lý do: Công cụ càng phức tạp hơn và nhiều tham số hơn nên mô hình dễ học vết chính xác

Độ tin cậy: 85%

Kiểm chứng: Đúng

- Training PPL của Trigram MLE chỉ là 19.71

- Tuy nhiên, khi dùng Laplace smoothing với LV quá lớn, Trigram Laplace bị phát nổ.

5 Prediction 5: Trigram và Bigram trên ~~test~~ corpus nhỏ

Dự đoán: Trigram không chắc tốt hơn Bigram, Bigram/Unigram thậm chí có thể vượt hơn khi dữ liệu ít

Lý do: Dữ liệu nhỏ khiến hầu hết Trigram bị thiếu, mô hình phụ thuộc hoàn toàn vào smoothing nhân tạo làm loãng phân phối xác suất

Độ tin cậy: 80%

Kiểm chứng: Đúng

Trên tập Test, Unigram đạt PPL tốt nhất, kế tiếp là Bigram còn Trigram tệ nhất